MINI project 01 - IMDB Web scrapping

```
library(tidyverse)
library(rvest) # scrape data from internet
Warning message in system("timedatectl", intern = TRUE):
"running command 'timedatectl' had status 1"
Warning message:
"Failed to locate timezone database"
- Attaching packages -
                                                        - tidyverse 1.3.1

√ ggplot2 3.3.5  √ purrr 0.3.4

- Conflicts -
                                                   tidyverse_conflicts()
x dplyr::filter() masks stats::filter()
x purrr::flatten() masks jsonlite::flatten()
x dplyr::lag() masks stats::lag()
Attaching package: 'rvest'
```

```
url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"
print(url)</pre>
```

[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"

```
# read html
imdb <- read_html(url)
imdb

{html_document}</pre>
```

```
<html xmlns:og="http://ogp.me/ns#" xmlns:fb="http://www.facebook.com/2008/fbml"</pre>
[1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset=UTF-8 .
[2] <body id="styleguide-v2" class="fixed">\n
                                                                      <img height="1" widt .</pre>
# movie title
titles <- imdb %>%
     html_nodes("h3.lister-item-header") %>%
     html_text2()
# movie rating
ratings <- imdb %>%
     html_nodes("div.ratings-imdb-rating") %>%
     html_text2()
titles [1:10]
ratings [1:10]
'1. The Shawshank Redemption (1994)' · '2. The Godfather (1972)' · '3. The Dark Knight (2008)' ·
'4. The Lord of the Rings: The Return of the King (2003)' · '5. Schindler\'s List (1993)' ·
'6. The Godfather Part II (1974)' · '7. 12 Angry Men (1957)' · '8. Pulp Fiction (1994)' · '9. Inception (2010)' ·
'10. The Lord of the Rings: The Two Towers (2002)'
'9.3' · '9.2' · '9.0' · '9.0' · '9.0' · '9.0' · '9.0' · '8.9' · '8.8' · '8.8'
## num fo vote
num_votes <- imdb %>%
     html_nodes("p.sort-num_votes-visible") %>%
     html_text2()
# build a data set
df <- data.frame(</pre>
    title = titles,
     rating = ratings,
     num_vote = num_votes
head(df)
```

A data.frame: 6 × 3				
	title	rating	num_vote	
	<chr></chr>	<chr></chr>	<chr></chr>	
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,663,424 Gross: \$28.34M Top 250: #1	
2	2. The Godfather (1972)	9.2	Votes: 1,845,750 Gross: \$134.97M Top 250: #2	
3	3. The Dark Knight (2008)	9.0	Votes: 2,636,372 Gross: \$534.86M Top 250: #3	
4	4. The Lord of the Rings: The Return of the King (2003)	9.0	Votes: 1,836,307 Gross: \$377.85M Top 250: #7	
5	5. Schindler's List (1993)	9.0	Votes: 1,348,741 Gross: \$96.90M Top 250: #6	
6	6. The Godfather Part II (1974)	9.0	Votes: 1,264,268 Gross: \$57.30M Top 250: #4	

Mini project 02 - Spec Phone Database

```
— Conflicts
X dplyr::filter() masks stats::filter()
X purrr::flatten() masks jsonlite::flatten()
X dplyr::lag() masks stats::lag()

Attaching package: 'rvest'
```

```
url <- read_html("https://specphone.com/Samsung-Galaxy-A04.html#specification")</pre>
```

```
att <- url %>%
  html_nodes("div.topic") %>%
  html_text2
```

```
value <- url %>%
  html_nodes("div.detail") %>%
  html_text2()
```

```
data.frame(attibute = att, value = value)
```

A data.frame: 31×2

A data.frame: 31 × 2				
attibute	value			
<chr></chr>	<chr></chr>			
วันเปิดตัว	ตุลาคม 2565			
วันวางจำหน่าย	ยังไม่วางจำหน่าย			
ขนาด	164.40 x 76.30 x 9.10 มม.			
น้ำหนัก	192 กรัม			
วัสดุ	Glass front, plastic back, plastic frame			
SIM	รองรับ 2 ชิมการ์ด (nano sim, nano sim)			
Technology	HSPA 42.2/5.76 Mbps, LTE-A			
2G	850/900/1800/1900			
3G	850/900/1900/2100			
4G	850/900/1900/2100/2600			
5G	-			
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A			
ประเภท	PLS LCD			
ขนาดหน้าจอ	6.50 นิ้ว			
ความละเอียด	720 x 1600 pixels			
ระบบปฏิบัติการ	Android 12			
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz			
ชิปกราฟิก	PowerVR GE8322			
หน่วยความจำ	3 GB			
ความจุ	32 GB			
Memory Card	microSD (1)			
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)			
ความละเอียดวีดีโอ	1080p@30fps			
กล้องหน้า	ดัวที่ 1: 5 MP, f/2.2			
Bluetooth	5.0, A2DP, LE			
Wi-Fi	802.11 a/b/g/n/ac, dual-b			
USB	Type-C			
GPS	GLONASS, GALILEO, BDS			
NFC	ไม่รองรับ			
ความจุ	5,000 mAh			
ประเภท	Non-removable Li-Po Batt			

```
# link to all samsung phone
links <- samsung_url %>%
  html_nodes("li.mobile-brand-item a") %>%
  html_attr("href")
```

```
full_links <- paste0("https://specphone.com",links)</pre>
```

```
[1] "Pregress...."
[1] "Pregress...."
[1] "Pregress...."
[1] "Pregress...."
```

```
print(head(result),3)
```

```
attribute
                                                       value
1
      วันเปิดตัว
                                               มิถุนายน 2565
2 วันวางจำหน่าย
                                             ยังไม่วางจำหน่าย
                                165.40 x 76.90 x 8.40 มม.
3
         ขนาด
        น้ำหนัก
4
                                                     192 กรัม
5
          วัสดุ Glass front, plastic back, plastic frame
                     รองรับ 2 ซิมการ์ด (nano sim, nano sim)
```

```
# write to csv
write_csv(result, "result_web_scrapping.csv")
```